

O que fazer?

Inicialmente, você deve escolher um conjunto de dados presente na lista disponibilizada no final deste parágrafo. Após essa seleção, você deve escrever seu nome na linha respectiva ao conjunto de dados escolhido. A escolha deve ser realizada em um dos conjuntos de dados que ainda não foi escolhido por outro aluno. (link: [CONJUNTOS DE DADOS](#))

De posse do conjunto de dados, inicialmente deve ser realizada uma exploração dos dados, construa gráficos e/ou tabelas para exibir informações sobre os dados. Como dicas, podem ser realizadas as abordagens:

- Se possível ($1 < p \leq 3$), a construção do gráfico de espalhamento para destacar como as classes estão dispostas.
- Análises estatísticas de cada preditor ou cada preditor por classe. Nesse caso, pode-se utilizar a biblioteca matplotlib e seaborn para construção de boxplots exibindo as características estatísticas pontuadas. Segue link referência para construção de um [box plot](#).
- Caso não consiga criar o gráfico, faça a construção da tabela com informações de média, desvio-padrão, menor valor, maior valor para cada grupo de classe, bem como para o conjunto de dados em geral.

Obs 1: Caso o conjunto de dados escolhido utilize imagens para classificação, é interessante o uso da biblioteca **opencv**. Para realizar sua instalação, basta utilizar o seguinte comando no terminal:

- `pip install opencv-python`

Com esta biblioteca, é possível fazer as aquisições e transformações necessárias de modo que as imagens possam ser utilizadas nos algoritmos de aprendizado de máquina vistos em sala de aula.

Observação 2: Como os conjuntos de dados podem possuir mais de 2 classes, faz sentido testar se as implementações desenvolvidas estão funcionando corretamente ao utilizar um conjunto de dados com uma quantidade menor de amostras e apenas duas classes. Desta maneira, para esse teste inicial use o conjunto de dados em **Spiral** já disponibilizado no AVA.

Grupos de Classificadores

Em seguida, deve-se realizar:

1. Implementação dos seguintes classificadores:
 - (a) Perceptron Simples (ou rede Perceptron Simples se necessário).
 - (b) ADALINE (ou MADALINE se necessário).
 - (c) Perceptron de Múltiplas Camadas (os detalhes sobre sua arquitetura são exibidos na próxima seção).
 - (d) Rede de Função de Base Radial (RBF).
2. No processo de treinamento, separe os dados em 80% para treinamento e os 20% para avaliar o desempenho do modelo.
3. Repetir 100 vezes o processo de separação dos dados (treinamento/teste) e armazenar a taxa de acerto de cada uma das 100 rodadas. Guarde também a cada rodada, a matriz (ou vetor) de pesos de cada classificador.
4. Após o término das 100 rodadas de treinamento/teste estime os valores médio, mínimo, máximo, mediana e desvio-padrão da taxa de acerto para as 100 rodadas. Use a seguinte tabela como referência:

Além disso, faça uma análise de custo computacional das 100 rodadas computando as mesmas medidas para o tempo de treinamento. Além das comparações requisitadas, faça a construção do gráfico box plot em uma única tela de modo a comparar a taxa de acerto dos classificadores nas 100 rodadas.

Classificador	Média	Mediana	Mínimo	Máximo	Desvio-padrão
MLP					
Rede RBF					
LMQ					
PS					
ADALINE					

- Calcule a taxa média de acerto por classe.
- Para cada rodada, construa as matrizes de confusão obtidas para cada classificador. Contudo, no relatório exiba apenas as matrizes de confusão com a menor taxa de acerto e a maior taxa de acerto. Quais classes são mais fáceis de classificar? Quais são mais difíceis? Elencar possíveis explicações para os resultados.

Observações com relação à rede MLP

Para o trabalho, é necessário o desenvolvimento da rede MLP que realize a tarefa de classificação para o problema de reconhecimento de padrões. Antes de realizar as 100 rodadas deste modelo, é necessário a definição de seus hiperparâmetros. Assim, realize as seguintes análises:

- Escolha a função de ativação que estará presente em todos os neurônios artificiais da rede MLP (ex: Tan. Hiperbólica, Logística, etc). Explique o motivo da escolha!
- Escolha o método de normalização dos dados (ex: min-max(-1 a 1), Padronização, etc). Explique o motivo de sua escolha.
- A escolha dos hiperparâmetros da rede, conforme as discussões realizadas em sala (ou através do que está descrito nos slides). Os hiperparâmetros são:
 - Quantidade de camadas escondidas.
 - Quantidade de neurônios nas camadas escondidas.
 - Quantidade de neurônios na camada de saída.
 - Valor da precisão (ou critério de parada da convergência).
 - Número máximo de épocas.
 - Taxa de aprendizagem.
- Para essas escolhas, avalie a generalização do modelo pela medida de Acurácia e tempo de treinamento.
- Uma dica interessante para valores iniciais dos hiperparâmetros é o uso de alguma das regras descritas nos slides.
- Após a definição do modelo ideal (matrizes de pesos que melhor realizam generalização), faça a comparação deste modelo com os métodos presentes no respectivo grupo.
- Faça uma análise de sub-ajuste e sobreajuste para a rede MLP, ou seja, explore a quantidade mínima de neurônios e camadas que consiga resolver bem seu problema de classificação. Encontre também a partir de quantos neurônios a rede começa a fazer um sobreajuste.

4) Relatório

- Escreva um relatório, que contenha (OBS: As informações detalhadas do trabalho, podem ser encontradas no AVA):
 - Introdução.
 - Fundamentação Teórica/Revisão Bibliográfica.
 - Metodologia - O que foi desenvolvido ao longo do trabalho.

4. Resultados: Exiba gráficos (matrizes de confusão, boxplot) e tabelas com os valores de Acurácia, e Custo computacional. Para esses dois últimos preencher a tabela com (Média, Menor valor, Maior valor, Desvio Padrão e Mediana)
 5. Conclusões.
- Lembre-se que para um resultado mais próximo do real, deve-se executar o algoritmo em algumas rodadas. Se possível umas 100 rodadas. Neste caso, deve-se mostrar em tabelas os valores: Maior Acurácia, Menor Acurácia, Desvio Padrão, Acurácia Média, Medianas.